



UNIVERSIDAD DE MÁLAGA



E.T.S. INGENIERÍA
INFORMÁTICA
UNIVERSIDAD DE MÁLAGA

Grado en Ingeniería Informática

Mención en Computación

Análisis del rendimiento y consumo de modelos de IA para detección de intrusiones

Performance and consumption analysis of AI models for intrusion detection

Realizado por

Plácido Velasco Muñoz

Tutorizado por

Dr. Rodrigo Román Castro

Co-tutorizado por

Dr. Francisco José Jaime Rodríguez

Departamento

Departamento de Lenguajes y Ciencias de la Computación

Málaga, February 4, 2026



UNIVERSIDAD
DE MÁLAGA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA

GRADO EN INGENIERÍA INFORMÁTICA

Mención en Computación

**Análisis del rendimiento y consumo de modelos de
IA para detección de intrusiones**

**Performance and consumption analysis of AI
models for intrusion detection**

Realizado por

Plácido Velasco Muñoz

Tutorizado por

Dr. Rodrigo Román Castro

Co-tutorizado por

Dr. Francisco José Jaime Rodríguez

Departamento

Departamento de Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA

MÁLAGA, FEBRUARY 4, 2026

Resumen

Palabras clave:

Abstract

Keywords:

Agradecimientos

Resumen	1
Abstract	3
Agradecimientos	5
0.1 Obtención y Análisis de Datos	11
0.1.1 CIC-IDS-2017 DataSet	11
0.1.2 NUSW-NB15 DataSet	13
0.1.3 ToN_IoT DataSet	14
0.1.4 IOT-23 DataSet	16

1	Logo del Canadian Institute for Cybersecurity, entidad responsable de la publicación del dataset CIC-IDS-2017.	13
2	Logo de la University of New South Wales, entidad responsable de la publicación del dataset UNSW-NB15.	14
3	Logo de la University of New South Wales, entidad responsable de la publicación del dataset ToN_IoT.	16

Índice de Tablas

1	Archivos principales del dataset CIC-IDS-2017, su contenido y día de actividad	12
2	Resumen de los archivos principales y tipos de ataques presentes en UNSW-NB15 .	14
3	Principales tipos de ataques presentes en UNSW-NB15	14
4	Resumen del archivo principal y estructura del subconjunto de red de ToN_IoT	15
5	Principales tipos de ataques presentes en el subconjunto de red de ToN_IoT	16

0.1 Obtención y Análisis de Datos

Para cumplir con los objetivos de este Trabajo Fin de Grado, resulta imprescindible realizar una selección cuidadosa de los conjuntos de datos empleados en la fase experimental. En el contexto de los sistemas de detección de intrusiones basados en inteligencia artificial, los datasets no solo deben ser representativos de una amplia diversidad de ataques y comportamientos de red, sino que también deben permitir una **evaluación realista y rigurosa** de los modelos entrenados.

En particular, dado que este trabajo no se centra únicamente en la capacidad de detección, sino también en el rendimiento y el consumo de recursos computacionales, los conjuntos de datos seleccionados deben posibilitar el análisis de aspectos como la latencia de inferencia, el uso de CPU y memoria, y la escalabilidad de los modelos en distintos escenarios. El uso de datasets excesivamente simplificados o poco representativos podría conducir a conclusiones poco realistas, mientras que el empleo de conjuntos de datos desproporcionadamente grandes o complejos podría dificultar la reproducibilidad y el análisis experimental detallado.

Por este motivo, en este proyecto se han seleccionado datasets ampliamente utilizados en la literatura científica, que cubren diferentes entornos y tipologías de ataque, y que ofrecen un equilibrio adecuado entre realismo, diversidad y viabilidad experimental. Esta elección permite evaluar de forma comparativa el comportamiento de distintos modelos de aprendizaje automático y profundo.

0.1.1 CIC-IDS-2017 DataSet

El conjunto de datos CIC-IDS-2017 se ha seleccionado como dataset principal para la evaluación experimental de los modelos de detección de intrusiones desarrollados en este trabajo. Este dataset, publicado por el Canadian Institute for Cybersecurity (CIC), es uno de los conjuntos de datos más utilizados en la literatura reciente sobre sistemas IDS basados en aprendizaje automático y aprendizaje profundo, lo que lo convierte en una referencia estándar para estudios comparativos.

El CIC-IDS-2017 ofrece varias ventajas que lo hacen especialmente adecuado para este proyecto:

- **Realismo y diversidad de ataques:** Una de las principales ventajas de CIC-IDS-2017 es que ofrece un alto grado de realismo, ya que fue generado a partir de un entorno de red que simula el comportamiento de una infraestructura corporativa real. El tráfico benigno y malicioso fue capturado durante varios días consecutivos, incorporando una amplia variedad de ataques, entre los que se incluyen ataques de denegación de servicio (DoS y DDoS), escaneos de puertos, ataques de fuerza bruta, ataques web y tráfico asociado a botnets. Esta diversidad permite evaluar la capacidad de los modelos para detectar distintos patrones de comportamiento malicioso, tanto evidentes como más sutiles.
- **Formato y características:** El dataset proporciona características extraídas a nivel de flujo, lo que facilita su uso con modelos de aprendizaje automático clásicos y redes neuronales aplicadas

a datos tabulares. Este formato resulta especialmente adecuado para el objetivo de este trabajo, ya que permite analizar no solo la precisión de los modelos, sino también métricas relacionadas con el rendimiento computacional, como la latencia de inferencia y el consumo de recursos, sin necesidad de realizar un costoso procesamiento previo de tráfico en bruto (PCAPs).

- **Tamaño y estructura:** Otro aspecto clave que justifica el uso de CIC-IDS-2017 es su tamaño y estructura. El volumen de datos es suficientemente grande como para entrenar y evaluar modelos complejos, pero al mismo tiempo permite trabajar con subconjuntos bien definidos (por ejemplo, tráfico correspondiente a días o tipos de ataque concretos). Esto facilita la realización de experimentos controlados y reproducibles, así como el estudio del impacto de distintos hiperparámetros y configuraciones de los modelos sobre su rendimiento y eficiencia.
- **Comparabilidad y validez experimental:** El uso extensivo de CIC-IDS-2017 en trabajos previos permite comparar los resultados obtenidos con los de la literatura existente, reforzando la validez de las conclusiones del estudio. Aunque el dataset presenta algunas limitaciones conocidas, como el desbalanceo de clases o la presencia de características derivadas, estas reflejan problemas habituales en datos reales y son abordadas mediante un proceso de limpieza y preprocesamiento adecuado.

Tabla 1. Archivos principales del dataset CIC-IDS-2017, su contenido y día de actividad

Archivo CSV	Contenido principal	Día de actividad
Monday-WorkingHours	Tráfico exclusivamente benigno.	Lunes
Tuesday-WorkingHours	Tráfico benigno y ataques de fuerza bruta (FTP/SSH Patator).	Martes
Wednesday-WorkingHours	Tráfico benigno y ataques de denegación de servicio (DoS/DDoS) y Heartbleed.	Miércoles
Thursday-Morning-WebAttacks	Ataques web (Brute Force, XSS, SQL Injection).	Jueves
Thursday-Afternoon-Infiltration	Escenarios de infiltración en la red.	Jueves
Friday-Morning-Botnet	Tráfico benigno y ataques de Botnets (ARES).	Viernes
Friday-Afternoon-DDoS/PortScan	Ataques de escaneo de puertos y DDoS.	Viernes

En resumen, la elección del dataset CIC-IDS-2017 responde a la necesidad de contar con un conjunto de datos realista, diverso y adecuado para evaluar tanto la precisión como el rendimiento computacional de los modelos de detección de intrusiones basados en inteligencia artificial. Su uso permitirá obtener conclusiones relevantes y aplicables a escenarios reales de ciberseguridad.



Figura 1. Logo del Canadian Institute for Cybersecurity, entidad responsable de la publicación del dataset CIC-IDS-2017.

0.1.2 UNSW-NB15 DataSet

El conjunto de datos UNSW-NB15 se ha seleccionado como dataset complementario en este trabajo con el objetivo de reforzar la validez de los resultados obtenidos y evaluar el comportamiento de los modelos en un entorno de datos distinto al representado por CIC-IDS-2017. Este dataset fue desarrollado por la University of New South Wales (UNSW) con el propósito de superar algunas de las limitaciones presentes en conjuntos de datos anteriores y proporcionar un escenario más realista para la evaluación de sistemas de detección de intrusiones.

La utilización de este dataset permite contrastar si las conclusiones obtenidas con CIC-IDS-2017 se mantienen cuando los modelos se enfrentan a un dataset con características, distribución y tipos de ataque diferentes, evitando que los resultados dependan de un único conjunto de datos.

Estructura y contenido del dataset

UNSW-NB15 está compuesto por registros de tráfico de red generados mediante la combinación de tráfico real y tráfico sintético, con el fin de simular de forma controlada distintos escenarios de ataque. El dataset se distribuye en conjuntos de entrenamiento y prueba claramente diferenciados, lo que facilita la reproducibilidad experimental y reduce el riesgo de *data leakage* durante el proceso de evaluación.

Cada registro representa un flujo de red y se describe mediante un conjunto de características heterogéneas, que incluyen métricas relacionadas con el tráfico, información del protocolo y estadísticas de comportamiento.

En cuanto a las etiquetas, UNSW-NB15 incluye tráfico benigno (0) y múltiples tipos de ataques (1), como DoS, Exploits, Fuzzers, Reconnaissance o Generic attacks. Esta diversidad permite abordar tanto problemas de clasificación binaria como multiclase, aunque el dataset presenta un desbalanceo significativo entre clases, reflejando una situación habitual en entornos reales.

En resumen, la inclusión de UNSW-NB15 resulta especialmente relevante para los objetivos de este trabajo por varias razones. En primer lugar, su tamaño intermedio permite realizar experimentos

Tabla 2. Resumen de los archivos principales y tipos de ataques presentes en UNSW-NB15

Archivo	Descripción	Tipo de datos
UNSW_NB15_training-set.csv	Datos de entrenamiento, incluye tráfico benigno y ataques.	Entrenamiento
UNSW_NB15_testing-set.csv	Datos de prueba, incluye tráfico benigno y ataques.	Prueba

Tabla 3. Principales tipos de ataques presentes en UNSW-NB15

Tipo de ataque	Descripción
Fuzzers	Pruebas automáticas para encontrar vulnerabilidades.
Analysis	Ataques de análisis de red y escaneo.
Backdoor	Acceso no autorizado mediante puertas traseras.
DoS	Denegación de servicio.
Exploits	Explotación de vulnerabilidades conocidas.
Generic	Ataques genéricos de cifrado y descifrado.
Reconnaissance	Reconocimiento y recopilación de información.
Shellcode	Inyección de código malicioso.
Worms	Propagación de malware tipo gusano.

detallados de evaluación del rendimiento y consumo de recursos sin incurrir en los elevados costes computacionales asociados a datasets de mayor volumen. Esto lo convierte en un conjunto de datos adecuado para analizar métricas como la latencia de inferencia, el uso de CPU y memoria, y el impacto de distintos hiperparámetros de los modelos.

Finalmente, al presentar una distribución de datos y un conjunto de características diferentes a los de CIC-IDS-2017, UNSW-NB15 permite evaluar la capacidad de generalización de los modelos, analizando si su rendimiento y eficiencia se mantienen en escenarios distintos. Este aspecto es fundamental para extraer conclusiones robustas y evitar un sobreajuste de los resultados a un único dataset.



Figura 2. Logo de la University of New South Wales, entidad responsable de la publicación del dataset UNSW-NB15.

0.1.3 ToN_IoT DataSet

El conjunto de datos ToN_IoT (Telemetry of Network IoT) se ha incluido en este trabajo como dataset orientado a entornos IoT y edge computing, con el objetivo de evaluar el comportamiento de los modelos de detección de intrusiones en escenarios caracterizados por recursos limitados, alta heterogeneidad y requisitos estrictos de eficiencia. Este dataset fue desarrollado por la University of New South

Wales (UNSW) para cubrir las limitaciones de los conjuntos de datos tradicionales, que no representan adecuadamente el tráfico y los ataques presentes en infraestructuras IoT.

La principal motivación para utilizar ToN_IoT es que permite analizar cómo se comportan los modelos entrenados cuando se trasladan desde entornos de red corporativa a escenarios más cercanos al edge, donde el consumo de CPU, memoria y la latencia de inferencia adquieren un papel crítico. De este modo, ToN_IoT complementa a CIC-IDS-2017 y UNSW-NB15, ampliando el alcance experimental del trabajo hacia contextos más realistas desde el punto de vista del despliegue práctico de un IDS.

El dataset ToN_IoT se distribuye en múltiples subconjuntos que incluyen tráfico de red, telemetría de dispositivos IoT y registros de sistemas operativos. No obstante, con el fin de mantener la comparabilidad con los otros datasets empleados y reducir la complejidad experimental, en este trabajo se ha seleccionado exclusivamente el **subconjunto de tráfico de red**, descartando los datos multimodales y los registros específicos de sistemas operativos.

En concreto, se ha utilizado el conjunto `Train_Test_Network_dataset`, que proporciona los datos en formato CSV e incluye una partición predefinida de entrenamiento y prueba. Esta elección permite garantizar la reproducibilidad de los experimentos y evita la necesidad de definir manualmente estrategias de particionado adicionales.

Estructura y contenido del dataset

El subconjunto de red de ToN_IoT está compuesto por registros a nivel de flujo, donde cada fila representa una conexión de red y cada columna corresponde a una característica extraída automáticamente. Estas características incluyen métricas relacionadas con el tráfico, estadísticas temporales y atributos derivados del comportamiento de los protocolos de comunicación, lo que lo hace adecuado para su uso con modelos de aprendizaje automático clásicos y redes neuronales aplicadas a datos tabulares.

El archivo utilizado integra tanto los datos de entrenamiento como de prueba en un único CSV, incluyendo una columna específica que identifica a qué subconjunto pertenece cada registro. Esta estructura facilita el uso del dataset sin introducir *data leakage* y permite evaluar de forma consistente el rendimiento de los modelos.

En cuanto al etiquetado, el dataset distingue entre tráfico benigno y tráfico malicioso, lo que permite plantear el problema como una tarea de clasificación binaria, coherente con el enfoque adoptado en el resto de conjuntos de datos empleados en el proyecto.

Tabla 4. Resumen del archivo principal y estructura del subconjunto de red de ToN_IoT

Archivo	Descripción	Tipo de datos
Train_Test_Network_dataset.csv	Registros de tráfico de red IoT, con partición de entrenamiento y prueba, características extraídas y etiquetas de benigno/malicioso.	Entrenamiento y prueba

Tabla 5. Principales tipos de ataques presentes en el subconjunto de red de ToN_IoT

Tipo de ataque	Descripción
DoS/DDoS	Ataques de denegación de servicio, tanto dirigidos como distribuidos.
Reconnaissance	Escaneo y recopilación de información sobre la red y dispositivos.
Man-in-the-Middle	Intercepción y manipulación de comunicaciones.
Injection	Inyección de comandos maliciosos en protocolos o servicios.
Password attacks	Ataques de fuerza bruta y diccionario sobre credenciales.
XSS/SQL Injection	Explotación de vulnerabilidades web en dispositivos IoT.
Botnet	Tráfico generado por dispositivos comprometidos en redes botnet.



Figura 3. Logo de la University of New South Wales, entidad responsable de la publicación del dataset ToN_IoT.

En resumen, la inclusión de ToN_IoT aporta un valor diferencial al trabajo, ya que permite evaluar los modelos de detección de intrusiones en un entorno que refleja las limitaciones reales de dispositivos IoT, donde el uso de modelos complejos puede resultar inviable. Además, el uso de ToN_IoT permite analizar si las conclusiones obtenidas a partir de datasets más tradicionales se mantienen cuando los modelos se enfrentan a un contexto diferente, reforzando la robustez y generalización de los resultados.

0.1.4 IOT-23 DataSet

El conjunto de datos **IoT-23** se ha incorporado en este trabajo como dataset complementario orientado a entornos IoT reales, con el objetivo de analizar el comportamiento de los modelos de detección de intrusiones frente a tráfico real, alta variabilidad y limitaciones prácticas de procesamiento. IoT-23, desarrollado por el grupo Stratosphere IPS de la Czech Technical University (CTU), es uno de los conjuntos de datos más representativos para el estudio de amenazas dirigidas a dispositivos IoT.

A diferencia de otros datasets generados en entornos controlados o sintéticos, IoT-23 se basa en capturas reales de tráfico de red procedentes de dispositivos IoT infectados con malware, incluyendo botnets y amenazas persistentes. Cada escenario del dataset refleja el comportamiento de un dispositivo comprometido durante periodos prolongados, aportando un alto grado de realismo y permitiendo evaluar los modelos frente a patrones de ataque complejos y no triviales.

Estructura y contenido del dataset

IoT-23 se distribuye en forma de escenarios independientes, donde cada uno representa una captura concreta asociada a un tipo específico de malware o comportamiento malicioso. Estos escenarios se almacenan en carpetas separadas y presentan tamaños muy variables, desde unos pocos megabytes

hasta decenas de gigabytes.

Debido al elevado volumen de datos, en este trabajo se ha seleccionado un subconjunto reducido de escenarios representativos, priorizando aquellos de tamaño pequeño y medio para mantener la viabilidad experimental y la reproducibilidad. En concreto, se han utilizado los archivos `capture-1-1.labeled` y `capture-7-1.labeled`, que permiten analizar el impacto del tráfico IoT real sobre el rendimiento y la eficiencia de los modelos sin incurrir en un coste computacional excesivo.

Los datos de IoT-23 se proporcionan principalmente en forma de logs de red etiquetados generados por Zeek, con extensión `.labeled`. Cada archivo contiene registros estructurados a nivel de conexión, donde cada fila representa un flujo de red y las columnas incluyen características como direcciones IP, puertos, protocolo, duración de la conexión y métricas de tráfico, junto con una etiqueta que indica si el flujo es benigno o malicioso. Para facilitar su integración con las herramientas de análisis y los modelos empleados, estos archivos se han convertido a formato CSV, manteniendo íntegramente el etiquetado original.

Dado que algunos archivos pueden superar el gigabyte de tamaño, el procesamiento se realiza mediante técnicas de *chunking*, evitando la carga completa en memoria y permitiendo analizar grandes volúmenes de tráfico de forma eficiente. Este enfoque resulta especialmente adecuado para evaluar métricas relacionadas con el rendimiento y el consumo de recursos, aspectos centrales en este trabajo.

Formulación del problema y etiquetado

Para homogeneizar la evaluación entre los distintos conjuntos de datos, la detección de intrusiones en IoT-23 se plantea como una tarea de clasificación binaria, donde:

- 0 representa tráfico benigno.
- 1 representa tráfico malicioso.

Esta formulación permite comparar directamente los resultados obtenidos con IoT-23 respecto a los de CIC-IDS-2017, UNSW-NB15 y ToN_IoT, y es coherente con el funcionamiento de muchos sistemas IDS en entornos reales.

Importancia de IoT-23 en el contexto del proyecto

La inclusión de IoT-23 aporta un valor diferencial al permitir evaluar los modelos frente a tráfico IoT realista, que no sigue necesariamente patrones sintéticos ni controlados. Esto es especialmente relevante para analizar el comportamiento de los modelos en términos de latencia, consumo de recursos y escalabilidad ante datos con alta variabilidad y ruido. En este trabajo, IoT-23 se utiliza principalmente como banco de pruebas para el análisis de eficiencia y comportamiento en escenarios IoT, reforzando la validez externa de los resultados y la aplicabilidad práctica de los modelos en entornos reales.



UNIVERSIDAD
DE MÁLAGA

| **uma.es**

ETS. de Ingeniería Informática
Bulevar Louis Pasteur, 35
Campus de Teatinos
29071 Málaga